

为什么需要并行计算？

1. 提高计算机性能的主要手段 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_
2. \_\_\_\_\_
3. \_\_\_\_\_
4. \_\_\_\_\_

弗林分类 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_ 4. \_\_\_\_\_

并行类型分类 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_ ( \_\_\_\_\_ )

存储访问结构分类 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_

系统类型分类 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_ 4. \_\_\_\_\_

并行程序设计模型/方法分类 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_

并行计算的主要技术问题

1. \_\_\_\_\_
2. \_\_\_\_\_
3. \_\_\_\_\_
4. \_\_\_\_\_
5. \_\_\_\_\_
6. \_\_\_\_\_
7. \_\_\_\_\_
8. \_\_\_\_\_
9. \_\_\_\_\_

Amdahl 定律揭示了 \_\_\_\_\_

MapReduce 定义：MapReduce 是 \_\_\_\_\_ 的 1. \_\_\_\_\_; 2. \_\_\_\_\_, 3. \_\_\_\_\_

对付大数据并行处理： \_\_\_\_\_

上升到抽象模型： \_\_\_\_\_

上升到构架： \_\_\_\_\_

MapReduce 提供的主要功能： \_\_\_\_\_、\_\_\_\_\_、\_\_\_\_\_、\_\_\_\_\_、\_\_\_\_\_

MapReduce 主要设计思想与特点：

1. \_\_\_\_\_
2. \_\_\_\_\_
3. \_\_\_\_\_
4. \_\_\_\_\_
5. \_\_\_\_\_
6. \_\_\_\_\_ ( \_\_\_\_\_ )

MapReduce 的工作过程

1. \_\_\_\_\_
2. \_\_\_\_\_
3. \_\_\_\_\_
4. \_\_\_\_\_
5. \_\_\_\_\_
6. \_\_\_\_\_
7. \_\_\_\_\_
8. \_\_\_\_\_

9. \_\_\_\_\_

MapReduce 失效处理与性能优化方面的主要措施

1. 失效处理 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_

2. 性能优化三点: 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_

Google GFS 基本设计原则

1. \_\_\_\_\_

2. \_\_\_\_\_

3. \_\_\_\_\_

Google GFS Master 的主要作用: 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_

BigTable 设计动机和目标:

1. \_\_\_\_\_

2. \_\_\_\_\_

3. \_\_\_\_\_

Combiner 设计目的与作用: \_\_\_\_\_

Partitioner 设计目的与作用: \_\_\_\_\_

InputFormat: \_\_\_\_\_

InputSplit: \_\_\_\_\_

RecordReader: \_\_\_\_\_

NameNode: \_\_\_\_\_

DataNode: \_\_\_\_\_

JobTracker: \_\_\_\_\_

TaskTracker: \_\_\_\_\_

HDFS 基本特征

1. \_\_\_\_\_

2. \_\_\_\_\_

3. \_\_\_\_\_

4. \_\_\_\_\_

5. \_\_\_\_\_

6. \_\_\_\_\_

HDFS 基本文件访问过程

1. \_\_\_\_\_

2. \_\_\_\_\_

3. \_\_\_\_\_

HDFS 可靠性设计 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_ 4. \_\_\_\_\_ 5. \_\_\_\_\_

6. \_\_\_\_\_ 7. \_\_\_\_\_ 8. \_\_\_\_\_

HBase 设计目标: \_\_\_\_\_

HBase 功能特点: 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_ 4. \_\_\_\_\_ 5. \_\_\_\_\_

Hive 组成模块: 1. \_\_\_\_\_ 2. \_\_\_\_\_ 3. \_\_\_\_\_ 4. \_\_\_\_\_ 5. \_\_\_\_\_

什么是 Distributed Cache? \_\_\_\_\_

全局参数 Configuration 的目的? \_\_\_\_\_

什么时候实现 Writable 接口? \_\_\_\_\_

什么时候实现 WritableComparable 接口? \_\_\_\_\_

为什么有 Spark?

1. \_\_\_\_\_
2. \_\_\_\_\_
3. \_\_\_\_\_

Spark 的技术特点

1. \_\_\_\_\_
2. \_\_\_\_\_
3. \_\_\_\_\_

RDD: \_\_\_\_\_

Application: \_\_\_\_\_

Job: \_\_\_\_\_

Stage: \_\_\_\_\_

Task: \_\_\_\_\_

Spark 的执行过程

1. \_\_\_\_\_
2. \_\_\_\_\_
3. \_\_\_\_\_
4. \_\_\_\_\_
5. \_\_\_\_\_
6. \_\_\_\_\_

构建 RDD 世系关系的优势: 1. \_\_\_\_\_ 2. \_\_\_\_\_

RDD 包含 \_\_\_\_\_ 、 \_\_\_\_\_ 、 \_\_\_\_\_ 、 \_\_\_\_\_